
# Tracing in Databend

## Tracing 赋能 Databend 的可观测性

Databend 贡献者养成计划

尚卓燃（PsiACE）

# 目录

CONTENT


WWW.DATABEND.COM

# Databend 与 Tracing

**初步了解 Databend 中的跟踪系统**

Databend 贡献者养成计划

# 什么是 Tracing



Tracing

Structured, application-level diagnostics

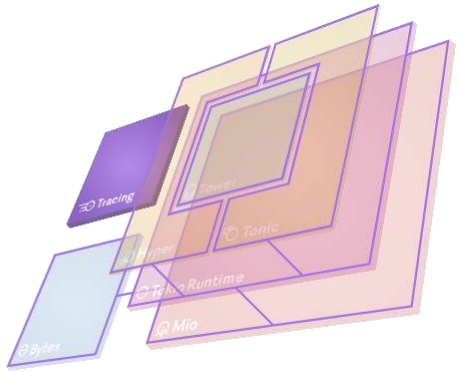

Tracing 由 Tokio 项目维护，无需 Tokio 运行时

检测 Rust 程序来收集结构化的、基于事件的诊断信息

https://github.com/tokio-rs/tracing

```rust
use tracing::{info, Level};
use tracing_subscriber;

fn main() {
    let collector = tracing_subscriber::fmt()
        // filter spans/events with level TRACE or higher.
        .with_max_level(Level::TRACE)
        // build but do not install the subscriber.
        .finish();

    tracing::collect::with_default(collector, || {
        info!("This will be logged to stdout");
    });
    info!("This will _not_ be logged to stdout");
}
```

# Tracing in Databend



Databend 的 tracing-subscriber 被统一整合在 common/tracing，由 query 和 meta 共同。

```rust
// Use env RUST_LOG to initialize log if present.
// Otherwise use the specified level.
let directives = env::var(EnvFilter::DEFAULT_ENV).unwrap_or_else(|_x| level.to_string());
let env_filter = EnvFilter::new(directives);
let subscriber = Registry::default()
    .with(env_filter)
    .with(JsonStorageLayer)
    .with(stdout_logging_layer)
    .with(file_logging_layer)
    .with(jaeger_layer);

#[cfg(feature = "console")]
let subscriber = subscriber.with(console_subscriber::spawn());
```

利用 tracing-bunyan-formatter 进行处理

存储在 _logs 目录下

opentelemetry-jaeger

tokio console 支持

# Tracing in Databend



具体到内部的 tracing ，大致有两种

```rust
// 普通：就像使用 log 一样，利用 info!、debug! 来收集信息

use common_tracing::tracing;

tracing::info!("{:?}", conf);
tracing::info!(
    "DatabendQuery v-{}",
    *databend_query::configs::DATABEND_COMMIT_VERSION,
);
```

```rust
// Instruments：在调用函数时创建并进入 tarcing span（跨度）
// span 是表示程序在特定上下文中执行的时间段

use common_tracing::tracing::debug_span;

#[tracing::instrument(level = "debug", skip_all)]
pub async fn read(&mut self) -> Result<DataBlock> {
...

  debug_span!("block_reader_read_column").or_current()

...

}
```

{"v":0,"name":"databend-query-test_cluster@0.0.0.0:3307","msg":"db name: db1, engine: ","level":50,"hostname":"dataslime","pid":127203,"time":"2022-01-06T04:14:57.4974979Z","target":"databend_query::catalogs::impls::mutable_catalog","line":154,"file":"query/src/catalogs/impls/mutable_catalog.rs"}

# “亲密接触”的小 Tips

Databend 与 Tracing “亲密接触” 的几种方式：

1. http tracing (不推荐)：访问 localhost:8080/v1/logs

2. stdout/filelog: 检查终端输出或 _logs 目录（根据配置）

3. system.tracing 表 ：执行 select * from system.tracing limit 20;

4. jaeger：运行 jaeger ，访问 http://127.0.0.1:16686/

5. console：按特定方式构建后，运行 tokio-console




# Jaeger 分布式跟踪

**使用 Jaeger 探索 Databend 运行原理**

Databend 贡献者养成计划

# Jaeger & OpenTelemetry



Jaeger 是一个开源的端到端分布式跟踪系统。由 Uber 捐赠给 CNCF 。它可以用于监视基于微服务的分布式系统:

- 分布式上下文传播
- 分布式事务监视
- 根本原因分析
- 服务依赖性分析
- 性能/延迟优化

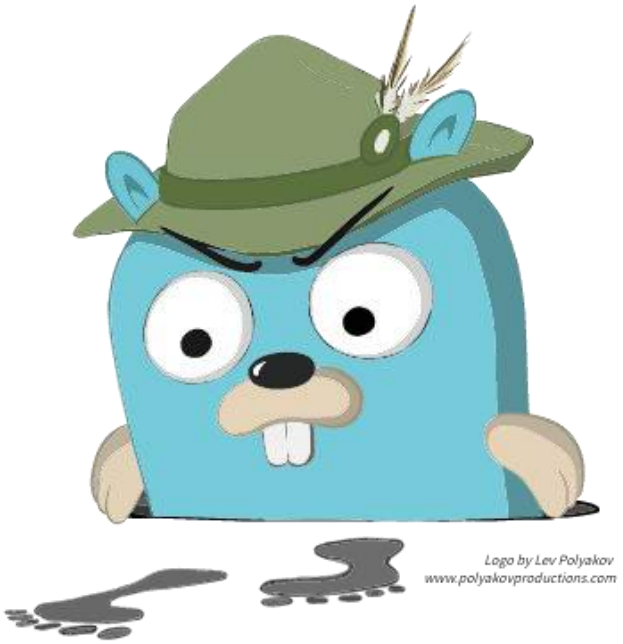


OpenTelemetry 是工具、API 和 SDK 的集合。使用它来检测、生成、收集和导出遥测数据（度量、日志和跟踪），以帮助您分析软件的性能和行为。

OpenTelemetry

CLOUD NATIVE
COMPUTING FOUNDATION
GRADUATED PROJECT

# Step by Step



1. 构建二进制程式
   cargo build （可以使用 --bin 指定）

2. 将日志级别设定为 DEBUG ，运行需要调试的应用程式
   例如，LOG_LEVEL=DEBUG ./databend-query

3. 运行 jaeger
   docker run -d -p6831:6831/udp -p6832:6832/udp -p16686:16686 jaegertracing/all-in-one:latest

3. 打开 http://127.0.0.1:16686/ 以查看 jaeger 收集的信息

# 结果探析



执行

```
CREATE TABLE t1(a INT);
INSERT INTO t1 VALUES(1);
INSERT INTO t1 SELECT * FROM t1;
```

可以得到下图所示跟踪结果

x轴是执行时刻，y轴是持续的时间，圆点反映 span 的聚集程度

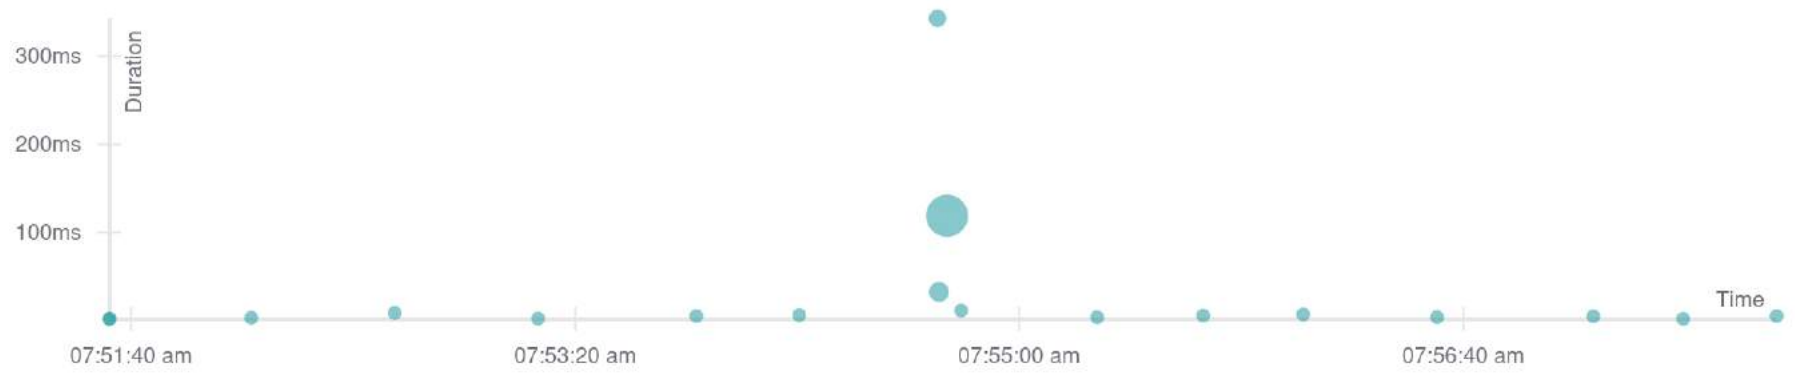

# 结果探析 - Timeline



左图是点击最大的圆点得到的跟踪情况：

使用 timeline 模式来展现 tracing 的各个跨度之间的关系。

以时间为主线进行分析,方便使用者观看在某个时间点观看程序信息

点开第一个跨度，可以看到这是 INSERT INTO t1 SELECT * FROM t1 查询时的情况

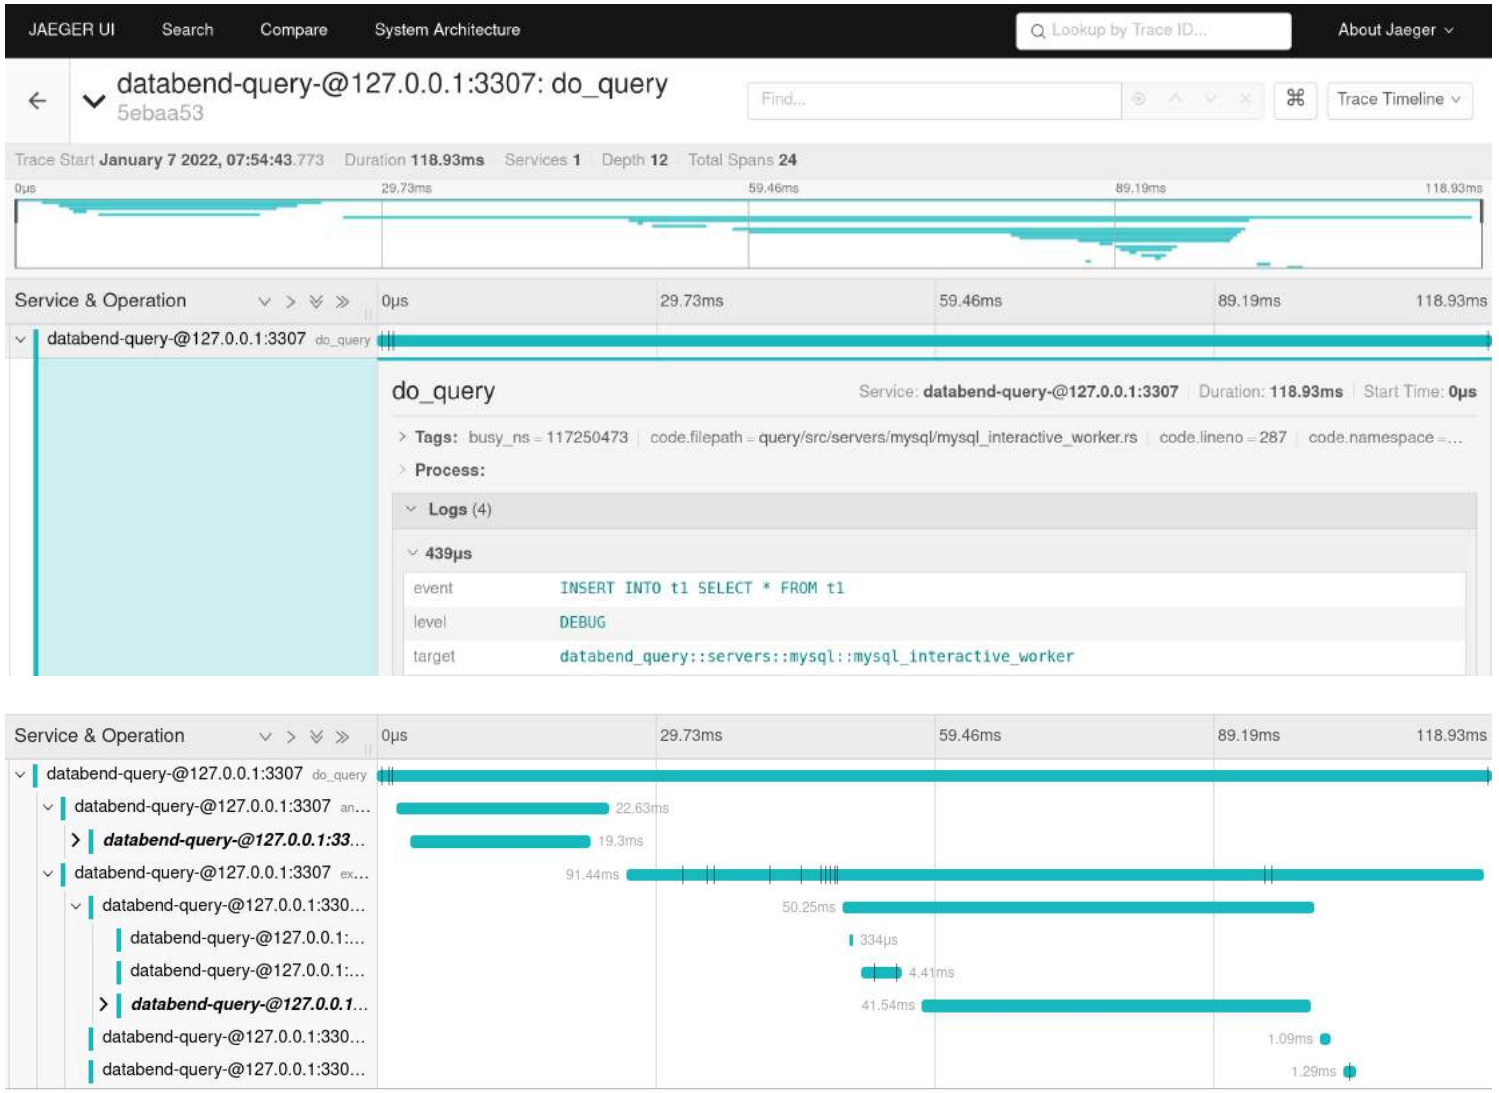

# 结果探析 - Graph

切换到 graph 模式，可以看到各个 span 之间的调用链，每个 span 具体用时 ,以及百分比
通过这个视图使用者很容易知道系统瓶颈,快速定位问题.

| | | |
|---|---|---|
| 1 / 0 | databend-query-@127.0.0.1:3307 | 19.3 ms |
| 19.303 ms (16.23 %) | analyze | 2.439 ms (12.64 %) |

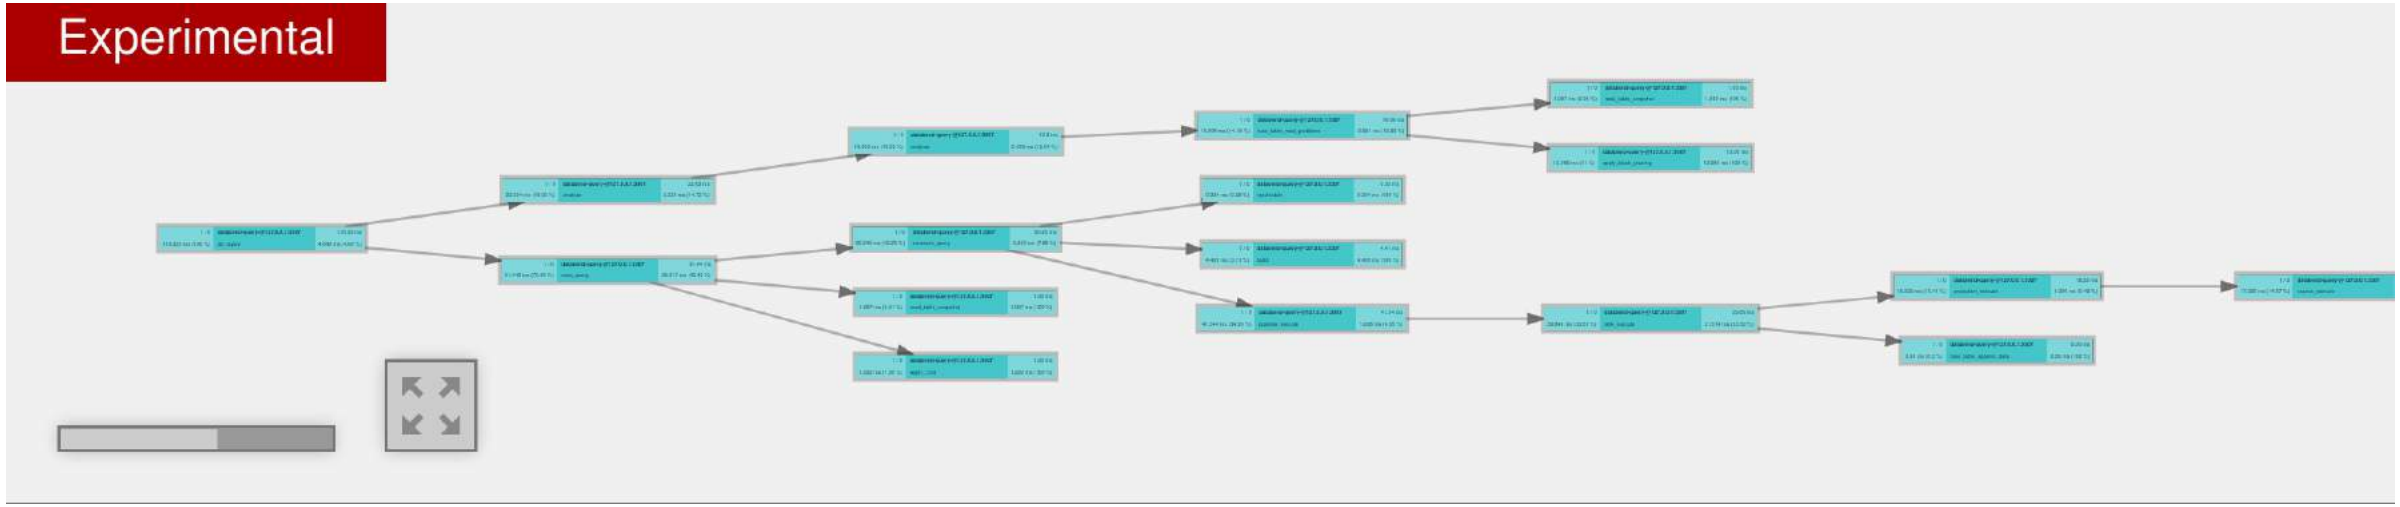

# 结果探析 - Compare

连起来的各个部分形成整个 trace 的调用链。

因为比较时一般会比较两个相同类型的调用，所以看到的是重合后的视图。

- 深绿色，表示这个 span 只存在于 trace-B 中，A 没有这个 span
- 深红色，表示这个 span 只存在于 trace-A 中，B 没有这个 span
- 浅绿色，表示这个span在trace-B（右边这个）的数量多
- 浅红色，表示这个span在trace-A（左边这个）的数量多

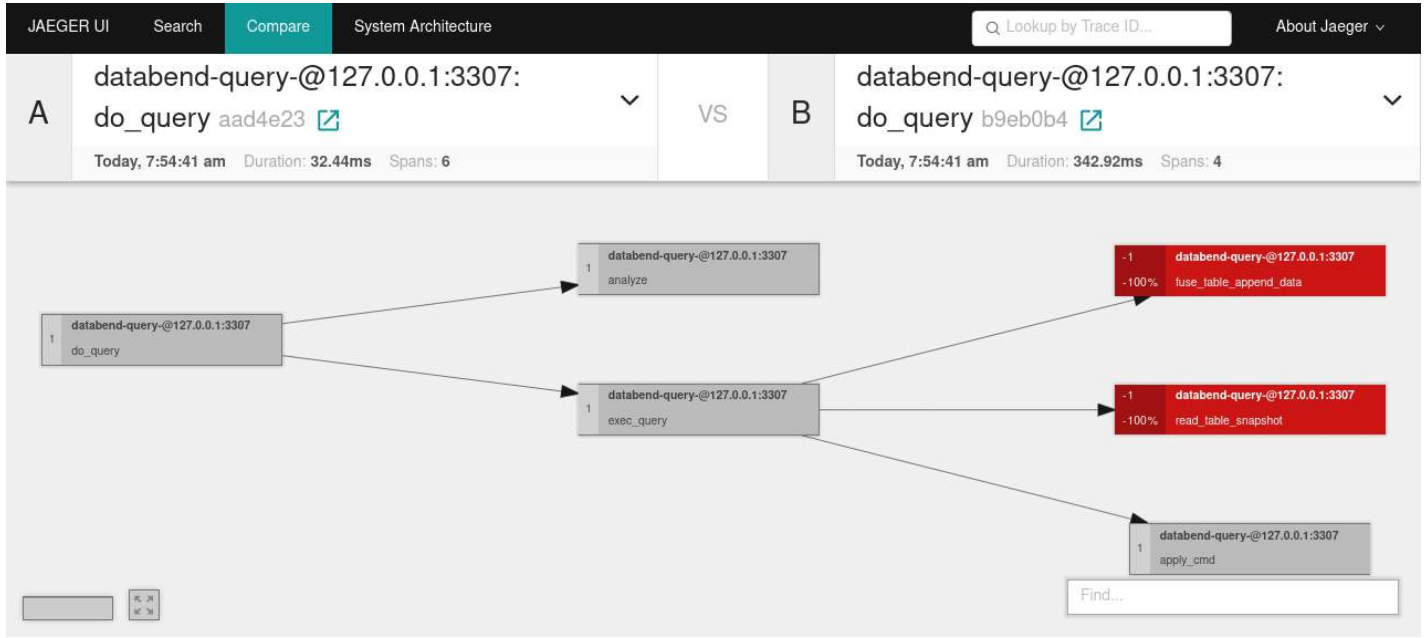




# 探迹 tokio-console

**tokio-rs 团队出品的诊断和调试工具**

Databend 贡献者养成计划

# console 是什么



tokio-console 是专为异步程序设计的调试与诊断工具，能够列出 tokio 的任务，提供对程序的任务和资源的实时、易于导航的视图，总结了它们的当前状态和历史行为。

- https://github.com/tokio-rs/console
- 传输诊断数据的协议
- 用于收集诊断数据的仪器
- 当然，用于展示和探索诊断数据的实用工具

```
tokio-console 0.1.0
Eliza Weisman <eliza@buoyant.io>, Tokio Contributors <team@tokio.rs>
The Tokio console: a debugger for async Rust.

USAGE:
    tokio-console [OPTIONS] [TARGET_ADDR]
```

# Step by Step



1. 使用特定的 rustflags 和 features 来构建：
   RUSTFLAGS="--cfg tokio_unstable" cargo build --features tokio-console
   也可以只构建单个二进制程式，使用 --bin 进行指定

2. 将日志级别设定为 TRACE ，运行需要调试的应用程式
   LOG_LEVEL=TRACE databend-query
   或者
   databend-meta --single --log-level=TRACE
   目前，因为潜在的端口抢占问题，一次只能对单个程序进行调试，所以只要待调试应用处于 TRACE 日志级别即可（当然，可以使用 TOKIO_CONSOLE_BIND 分别指定端口）

3. 运行 tokio-console # default connection: http://127.0.0.1:6669

# 结果探析 - 任务

先看什么是 tokio 任务

1. 任务是一个轻量级的、非阻塞的执行单元。类似操作系统的线程，但是是由 tokio 运行时管理，一般叫做“绿色线程”，与 Go 的 goroutine，Kotlin 的 coroutine 类似。

2. 任务是协同调度的。大多数操作系统实现抢占式多任务。操作系统允许每个线程运行一段时间，然后抢占它，暂停该线程并切换到另一个线程。另一方面，任务实现协同多任务。一个任务被允许运行直到它让出执行权，运行时会切换到执行下一个任务。

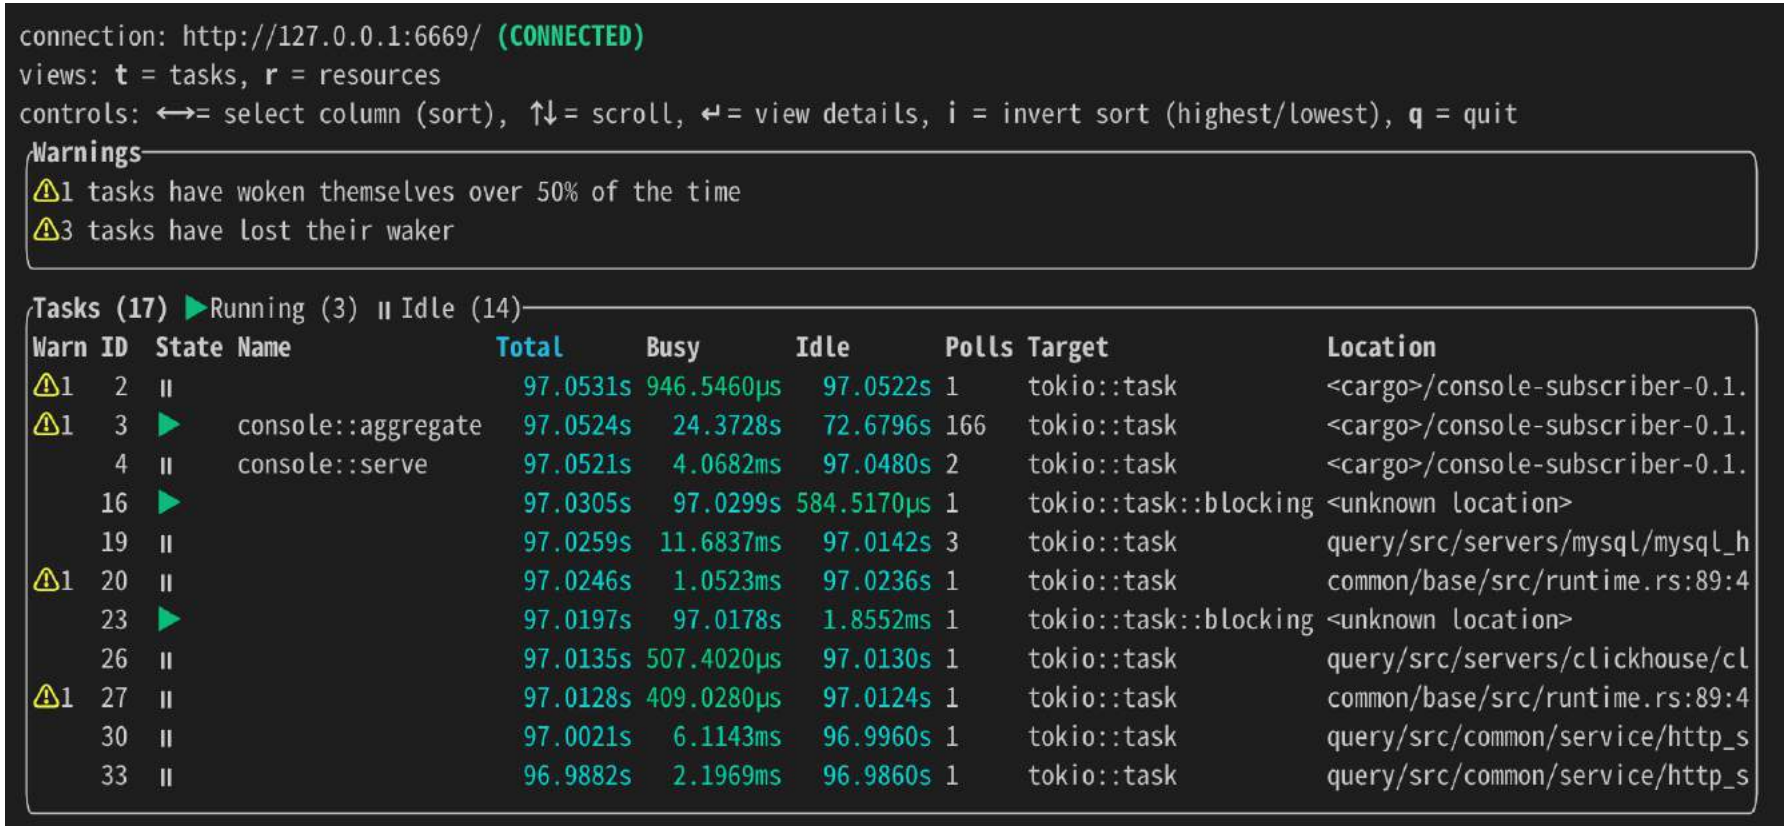

# 结果探析 - 基础视图



通过左右切换，可以得到总忙时间或轮询次数等指标对任务进行排序。控制台通过高亮来提示较大大差异，比如从毫秒到秒的切换。

控制台还实现了一个“警告”系统。通过监视应用程序中任务的运行时操作，控制台可以检测可能提示 bug 或性能问题的行为模式，并突出显示这些行为模式供用户分析。比如已经运行了很长时间而没有让步的任务，唤醒的次数比被其他任务唤醒的次数还要多的任务。

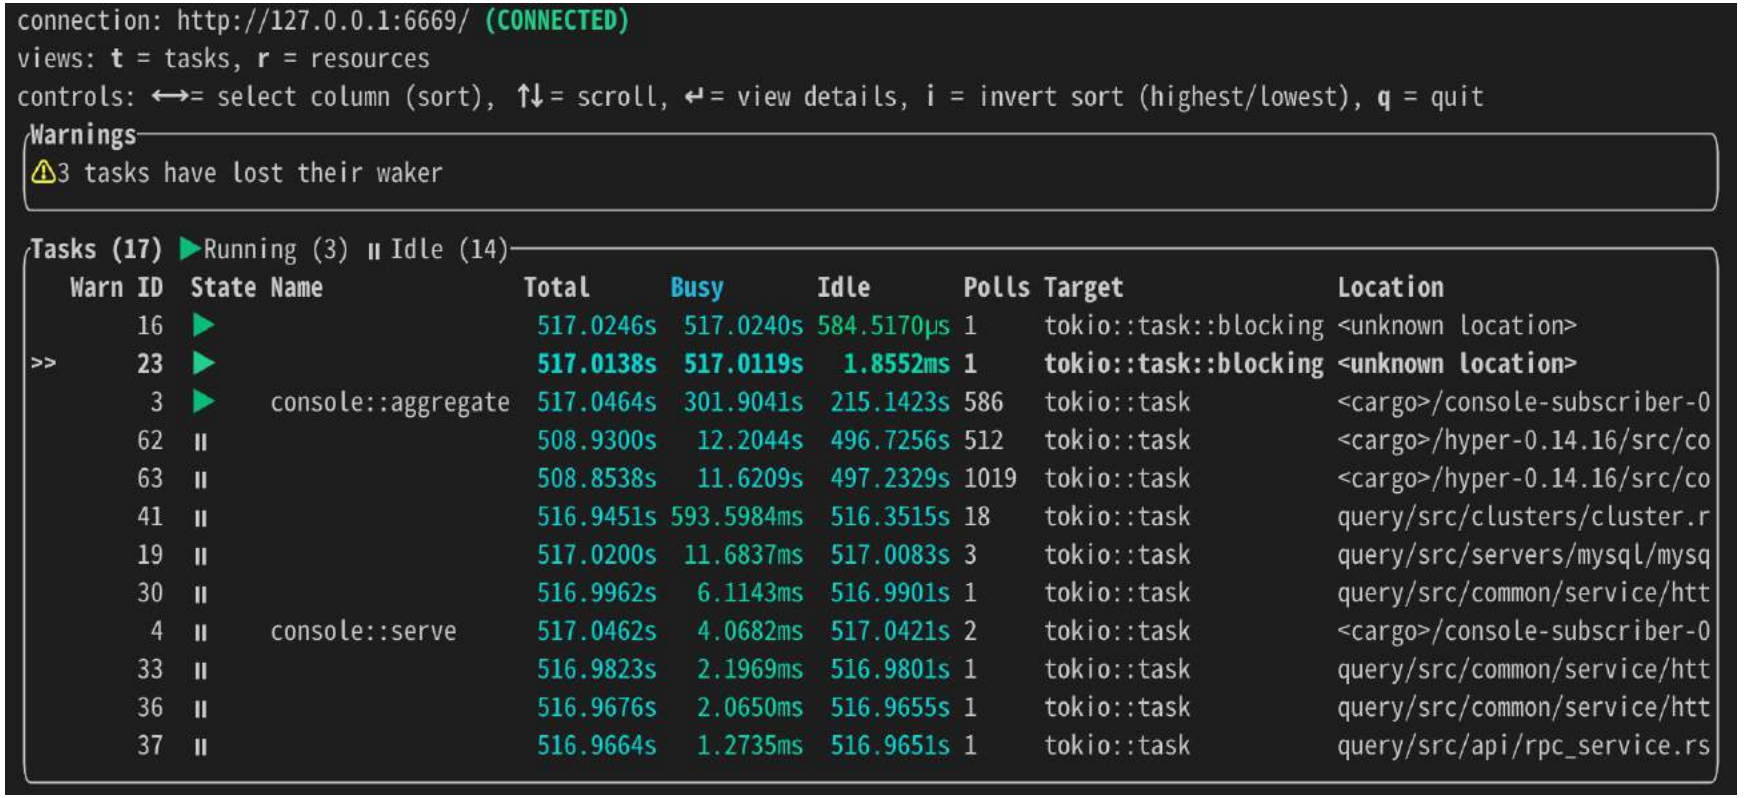

# 结果探析 - 任务视图



上下切换选中任务，enter 查看关于每个任务的翔实数据，比如轮询持续时间的直方图

不仅列出任务。console 还会插入异步互斥和信号量等资源。Tokio Console 的资源详细信息视图显示了哪些任务已经进入临界区，哪些任务正在等待获得访问权限。

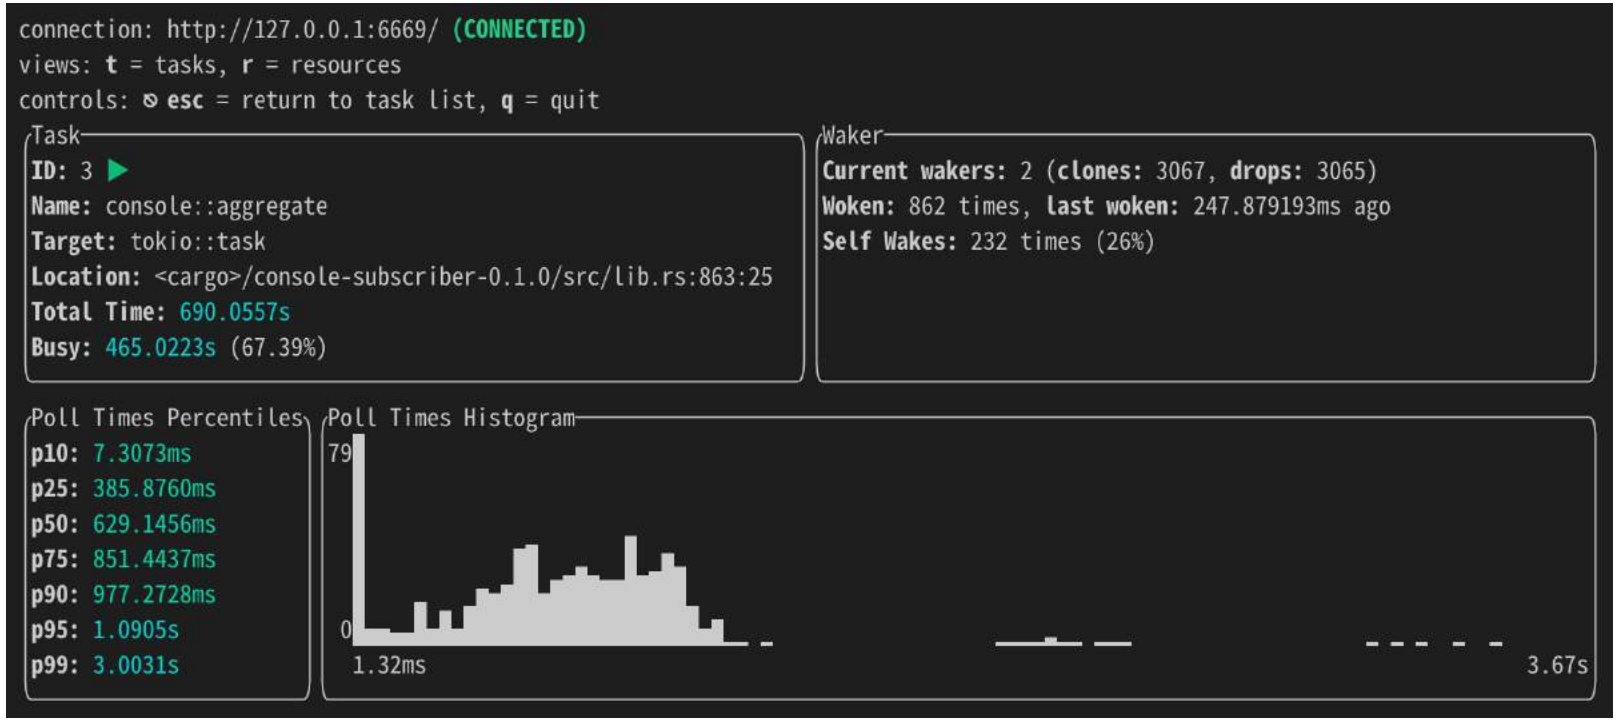




# 还能做什么

**与分布式跟踪和日志系统相关的一些其他内容**

Databend 贡献者养成计划

# 可观测性++



目前还有一系列关于可观测性和 Tracing 的 Issue:

- Configure different console ports for query and meta #3758
- Configure on jaeger tracing address similar to metrics api server #3633
- Support dashboard api to integrate with observability plugins such as prometheus and grafana #2346
- Summary of todos about distributed tracing #1227
- Query traces and analysis, based on user behavior. #1177
- Http stack traces #1085
- Shuffle read/write metrics #1004

另外，更进一步的考量是，如何基于可观测性来自动/半自动地发现问题并对系统进行调优

# 了解更多...

Tracing:
- https://github.com/tokio-rs/tracing
- https://docs.rs/tracing/latest/tracing/
- https://tokio.rs/blog/2019-08-tracing

Jaeger:
- https://github.com/open-telemetry/opentelemetry-rust/tree/main/opentelemetry-jaeger
- https://21-lessons.com/ship-rust-tracing-spans-to-jaeger/

tokio-console:
- https://github.com/tokio-rs/console
- https://hackmd.io/@aws-rust-platform/ByChcdB-t
- https://tokio.rs/blog/2021-12-announcing-tokio-console

Databend

# 讨论时间

## 感谢您的观看，让我们一起聊聊

Databend 贡献者养成计划

尚卓燃（PsiACE）